ĐẠI HỌC BÁCH KHOA HÀ NỘI TRƯ**ỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG**



BÁO CÁO

Lưu trữ và xử lý dữ liệu lớn Phân tích dữ liệu giao dịch tiền ảo

Nhóm HDSD

Sinh viên thực hiện	Mã sinh viên
Nguyễn Trọng Hải	20183730
Võ Việt Dũng	20183723
Lê Hữu Tiến Dũng	20183719
Ngô Đình Sáng	20183819

Giảng viên: TS. Đào Thành Chung

MỤC LỤC

MỤC LỤC	2
I. ĐẶT VẤN ĐỀ	3
II. MÔ TẢ BÀI TOÁN	
III. TRIỂN KHAI CÀI ĐẶT	3
1. Sơ đồ luồng hoạt động	3
2. Cài đặt cụm 3 máy ảo Hadoop Yarn	3
3. Cài đặt Spark	8
4. Cài đặt Kafka	10
IV. LẬP TRÌNH VÀ THỰC THI	10
1. Crawl và lưu trữ dữ liệu	10
1.1 Mã nguồn kafkaproducer.py	10
1.2 Mã nguồn kafkaconsumer.py	11
1.3 Dữ liệu được lưu trữ	11
2. Visualize dữ liệu	12
2.1 Tổng giao dịch trong 24h	12
2.2 Biểu đồ sự thay đổi % theo ngày trong 15 ngày	
2.3 Biểu đồ sự thay đổi giá trị theo ngày trong 15 ngày	15
3. Kết quả application đã chạy	16
V. KÉT LUẬN	17
VI. PHŲ LŲC	

I. ĐẶT VẤN ĐỀ

Xuất phát từ nhu cầu đầu tư ngày càng tăng cao, thời gian gần đây, dự đoán xu hướng tiền ảo đang rất được quan tâm.

Sự phát triển bùng nổ của Bitcoin cũng như các đồng tiền kỹ thuật số khác đã đưa thêm vào mạng Internet rất nhiều dữ liệu mới và ngày càng trở lên rất lớn.

Úng dụng kiến thức lưu trữ và xử lý dữ liệu lớn đã được học, nhóm muốn xử lý một đề thực tiễn, liên quan tới xu hướng của Top 200 đồng tiền ảo.

II. MÔ TẢ BÀI TOÁN

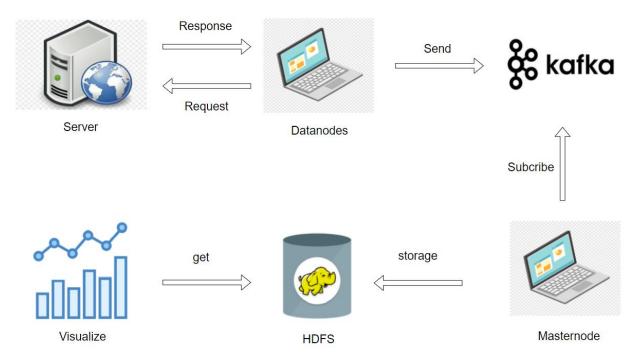
Lấy dữ liệu lịch sử các đồng tiền ảo từ ngày 28/4/2013 đến 29/12/2021.

Lưu trữ dữ liệu phân toán dưới dạng CSV.

Truy xuất dữ liệu từ file CSV để hiển thị.

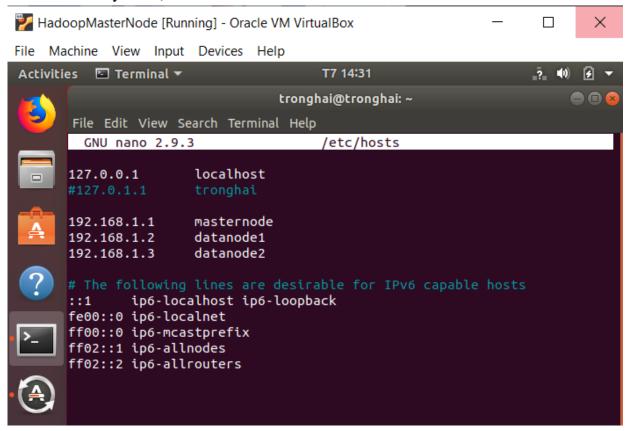
III. TRIỂN KHAI CÀI ĐẶT

1. Sơ đồ luồng hoạt động



2. Cài đặt cụm 3 máy ảo Hadoop Yarn

masternode: 192.168.1.1datanode1: 192.168.1.2datanode2: 192.168.1.3



- Sinh SSH-key ở masternode

```
hadoop@masternode:~$
hadoop@masternode:~$ ssh-keygen -t rsa
Generating public/private rsa key pair.
Enter file in which to save the key (/home/hadoop/.ssh/id_rsa):
Enter passphrase (empty for no passphrase):
Enter same passphrase again:
Your identification has been saved in /home/hadoop/.ssh/id_rsa.
Your public key has been saved in /home/hadoop/.ssh/id_rsa.pub.
The key fingerprint is:
SHA256:uDJe3vemQKCUo+wzJRywrtaMdtomYhDmvd/VrJnjv4Q hadoop@masternode
The key's randomart image is:
+---[RSA 2048]----+
|oo* o . S
       0
0++++ o .E +
+0+* =...0*
0.0.0...0*+*0
+----[SHA256]----+
```

- Copy SSH-key từ masternode đến 2 datanode

```
hadoop@masternode:~$ ssh-copy-id hadoop@datanode1
/usr/bin/ssh-copy-id: INFO: Source of key(s) to be installed: "/home/hadoop/.ss
h/id rsa.pub"
The authenticity of host 'datanode1 (192.168.1.2)' can't be established.
ECDSA key fingerprint is SHA256:h/F31SPUnJkoS923fs8DeRWyoxmxseF1lc6aRLqfLS0.
Are you sure you want to continue connecting (yes/no)? yes
/usr/bin/ssh-copy-id: INFO: attempting to log in with the new key(s), to filter
out any that are already installed
/usr/bin/ssh-copy-id: INFO: 1 key(s) remain to be installed -- if you are promp
ted now it is to install the new keys
hadoop@datanode1's password:
Number of key(s) added: 1
Now try logging into the machine, with: "ssh 'hadoop@datanode1'"
and check to make sure that only the key(s) you wanted were added.
hadoop@masternode:~$ ssh-copy-id hadoop@datanode2
/usr/bin/ssh-copy-id: INFO: Source of key(s) to be installed: "/home/hadoop/.ss
h/id rsa.pub"
The authenticity of host 'datanode2 (192.168.1.3)' can't be established.
ECDSA key fingerprint is SHA256:h/F31SPUnJkoS923fs8DeRWyoxmxseF1lc6aRLqfLS0.
Are you sure you want to continue connecting (yes/no)? yes
/usr/bin/ssh-copy-id: INFO: attempting to log in with the new key(s), to filter
out any that are already installed
/usr/bin/ssh-copy-id: INFO: 1 key(s) remain to be installed -- if you are promp
ted now it is to install the new keys
hadoop@datanode2's password:
Number of key(s) added: 1
Now try logging into the machine, with: "ssh 'hadoop@datanode2'"
and check to make sure that only the key(s) you wanted were added.
```

- Cài đặt hadoop-env.sh

```
##
# Many of the options here are built from the perspective that users
# may want to provide OVERWRITING values on the command line.
# For example:
# JAVA_HOME=/usr/java/testing hdfs dfs -ls
export JAVA_HOME=/usr/lib/jvm/java-8-openjdk-amd64/jre/
# Therefore, the vast majority (BUT NOT ALL!) of these defaults
# are configured for substitution and not append. If append
# is preferable, modify this file accordingly.
```

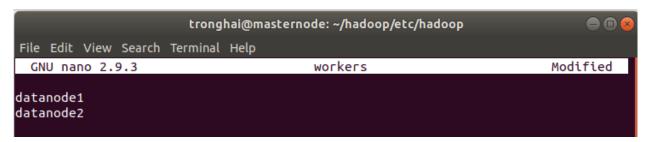
- Cài đặt core-site.xml

- Cài đặt hdfs-site.xml

- Cài đặt yarn-site.xml

```
tronghai@masternode: ~/hadoop/etc/hadoop
File Edit View Search Terminal Help
 GNU nano 2.9.3
                                                          yarn-site.xml
?xml version="1.0"?>
 Licensed under the Apache License, Version 2.0 (the "License");
 you may not use this file except in compliance with the License.
 You may obtain a copy of the License at
   http://www.apache.org/licenses/LICENSE-2.0
 Unless required by applicable law or agreed to in writing, software
 distributed under the License is distributed on an "AS IS" BASIS,
 WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
 See the License for the specific language governing permissions and
 limitations under the License. See accompanying LICENSE file.
<!-- Site specific YARN configuration properties -->
   property>
           <name>yarn.acl.enable</name>
           <value>0</value>
   cproperty>
           <name>yarn.resourcemanager.hostname</name>
           <value>192.168.1.1
   property>
           <name>yarn.nodemanager.aux-services
           <value>mapreduce shuffle</value>
 configuration>
```

- Cài đặt worker



- Cài đặt yarn-site.xml trên 2 datanode

```
HadoopDatanode1 [Running] - Oracle VM VirtualBox
                                                                                П
File Machine View Input Devices Help
GNU nano 2.9.3
                                                                                  Modified
                                         uarn-site.xml
!-- Site specific YARN configuration properties -->
          <name>yarn.acl.enable</name>
          <value>0</value>
  <name>yarn.resourcemanager.hostname</name>
          <value>192.168.1.1
  cproperty>
          <name>yarn.nodemanager.aux-services</name>
          <value>mapreduce_shuffle</value>
  <name>yarn.nodemanager.disk-health-checker.max-disk-utilization-per-disk-percentage</name>
      <value>98</value>
  </property>
🌠 HadoopDatanode2 [Running] - Oracle VM VirtualBox
                                                                                       Х
                                                                                File Machine View Input Devices Help
```

```
Modified
GNU nano 2.9.3
                                          yarn-site.xml
!-- Site specific YARN configuration properties -->
  cproperty>
          <name>yarn.acl.enable</name>
          <value>0</value>
  cproperty>
          <name>yarn.resourcemanager.hostname</name>
          <value>192.168.1.1
  cproperty>
          <name>yarn.nodemanager.aux-services</name>
          <value>mapreduce_shuffle</value>
  </property>
  cproperty>
      <name>yarn.nodemanager.disk-health-checker.max-disk-utilization-per-disk-percentage</name>
      <value>98</value>
  </property>
```

Khởi động yarn

```
hadoop@masternode:~$ yarn node -list
2022-01-03 21:41:24,194 INFO client.RMProxy: Connecting to ResourceManager at /192.168.1.1:8032
Total Nodes:2
Node-Id
Node-State Node-Http-Address
Number-of-Running-Containers
datanode2:38579
RUNNING
datanode2:8042
0
datanode1:45233
RUNNING
datanode1:8042
0
hadoop@masternode:~$
```

3. Cài đặt Spark

- Spark 2.4.7
- Cấu hình .profile

```
File Edit View Search Terminal Help

CNU mano 2.9.3

# -/.profile: executed by the command interpreter for login shells.
# This file is not read by bash(1), if -/.bash_profile or -/.bash_login
# exists.
# see /usr/share/doc/bash/examples/startup-files for examples.
# the default umask is set in /etc/profile; for setting the umask
# for ssh logins, install and configure the libpan-umask package.
# the default umask is set in /etc/profile; for setting the umask
# for ssh logins, install and configure the libpan-umask package.
# trunning bash
if [ -n "$BASH_VERSION" ]; then
# include .bashrc if it exists
if [ -f "SHOME/.bashrc" ]; then
. "SHOME/.bashrc" ]; then
PATH="SHOME/bin:$PATH"

ft

# set PATH so it includes user's private bin if it exists
if [ -d "SHOME/bin:$PATH"

ft

# Set PATH so it includes user's private bin if it exists
if [ -d "SHOME/.local/bin:$PATH"

Ft

PATH="SHOME/.local/bin:$PATH"

ft

PATH="SHOME/.local/bin:$PATH"

Ft

PATH="SHOME/.local/bin:Amone/hadoop/hadoop/sbin:/home/hadoop/spark/bin:$PATH
export HADOOP_COMON_LIB_NATVE_DIR=SHADOOP_HOME/lib/native
export SPARK_HOME=/home/hadoop/spark
export YSPARK_HOME=/home/hadoop/spark
export YSPARK_HOME=/home/hadoop/hadoop/lib/native:$LD_LIBRARY_PATH
```

- Cấu hình spark/conf/spark-default.conf

- Khởi động thử Spark 2.4.7 bằng pyspark

4. Cài đặt Kafka

- Kafka 2.8.1
- Cài đặt Kafka vào thư mục mong muốn là có thể sử dụng được.
- Mặc định kafka giao tiếp ở cổng 9092, zookeeper giao tiếp ở cổng 2181.
- Tạo topic mới bằng kafka.
- Topic "hdsd" tại masternode:9092

```
hadoop@masternode:~$ cd kafka
hadoop@masternode:~/kafka$ bin/kafka-topics.sh --create --topic hdsd --bootstrap-server masternode:9092
Created topic hdsd.
hadoop@masternode:~/kafka$
```

- Xem danh sách các topic tại masternode:2181

```
hadoop@masternode:~/kafka$ bin/kafka-topics.sh --list --zookeeper masternode:2181
hdsd
hdsd-test
hadoop@masternode:~/kafka$
```

IV. LẬP TRÌNH VÀ THỰC THI

- 1. Crawl và lưu trữ dữ liệu
- 1.1 Mã nguồn kafkaproducer.py
- File **kafkaproducer.py** nằm ở các máy datanode1 và datanode2 để tiến hành crawl dữ liệu và đẩy về masternode qua kafka.
- Cần install **kafka_python** để sử dụng kafka
- Sử dụng **BeatifulSoup** để lấy dữ liệu json.

```
from kafka import KafkaProducer
import requests
import time
from bs4 import BeautifulSoup
from datetime import timedelta, date

producer = KafkaProducer(bootstrap_servers='masternode:9092')

url_base = 'https://coinmarketcap.com/historical/'
def daterange(start_date, end_date):
    for n in range(int ((end_date - start_date).days)):
        yield start_date + timedelta(n)

start_date = date(2021, 12, 27)
end_date = date(2021, 12, 29)

def runaround(single_date):
    time.sleep(20)
    url = url base + single date.strftime("%Y%m%d")
```

```
print(url)
    r = requests.get(url)
    soup = BeautifulSoup(r.text, 'html.parser')
   return soup.find('script', type='application/json')
for single_date in daterange(start_date, end_date):
   url = url_base + single_date.strftime("%Y%m%d")
   print(url)
   r = requests.get(url)
   soup = BeautifulSoup(r.text, 'html.parser')
    s = soup.find('script', type='application/json')
   while s is None:
        s = runaround(single date)
   s=s.string
   start = s.find('[{"id":1,')
   s=s[start:]
   end = s.find(',"page":1')
   s=s[:end]
   producer.send('hdsd', bytes(s,'utf-8'))
   producer.flush()
   time.sleep(5)
```

1.2 Mã nguồn kafkaconsumer.py

- File **kafkaconsumer.py** nằm ở masternode để nhận dữ liệu json từ các datanode qua kafka và lưu lại vào file csv tại local.

```
from kafka import KafkaConsumer
import pandas as pd
from json import loads

consumer = KafkaConsumer(bootstrap_servers='masternode:9092')
consumer.subscribe('hdsd')
for message in consumer:
    print(message)
    message = message.value
    json = loads(message)
    df = pd.json_normalize(json)
    df.to_csv("bigdata.csv", mode='a', header=False)
```

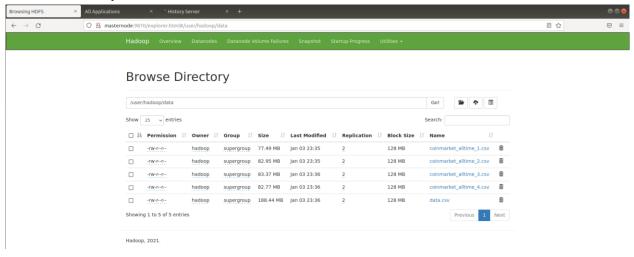
1.3 Dữ liệu được lưu trữ

- Dữ liệu sau đó được đẩy lên HDFS.

```
hadoop@masternode:~$ hdfs dfs -ls data

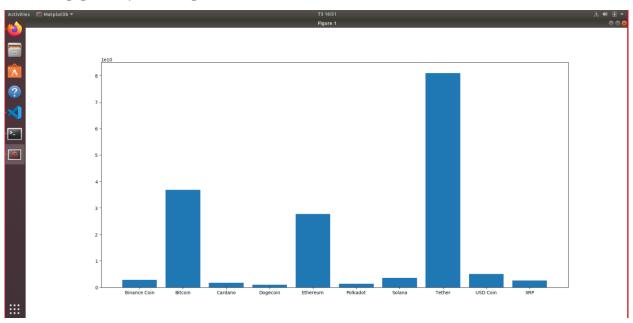
Found 5 items
-rw-r--r-- 2 hadoop supergroup 86978001 2022-01-03 23:35 data/coinmarket_alltime_1.csv
-rw-r--r-- 2 hadoop supergroup 87417187 2022-01-03 23:35 data/coinmarket_alltime_2.csv
-rw-r--r-- 2 hadoop supergroup 86788245 2022-01-03 23:36 data/coinmarket_alltime_4.csv
-rw-r--r-- 2 hadoop supergroup 197592315 2022-01-03 23:36 data/data.csv
hadoop@masternode:~$
```

- Dữ liệu cỡ 512MB



2. Visualize dữ liệu

2.1 Tổng giao dịch trong 24h



- Mã nguồn visualize1.py

```
import sys
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from pyspark.sql.session import SparkSession
from pyspark.sql import SQLContext
from pyspark import SparkConf, SparkContext

conf = SparkConf().setAppName("HDSD_Visual")
sc = SparkContext(conf=conf)
sc.setLogLevel("WARN")
spark = SparkSession(sc)
sqlContext = SQLContext(sc)
```

```
data = spark.read.csv(sys.argv[1], sep=',',inferSchema=True, header=True)
df = data.toPandas()
df.head()

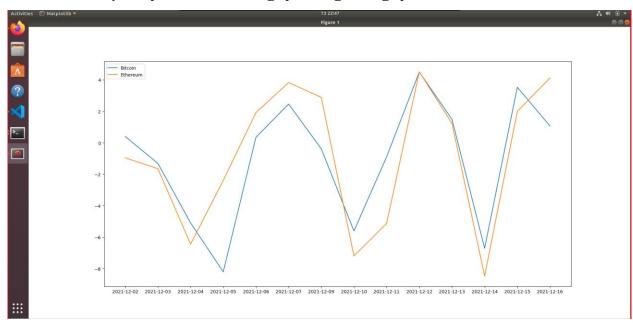
name = df['name'].head(20)
volume_24h = df['quote.USD.volume_24h'].head(20)
percent_change_1h = df['quote.USD.percent_change_1h'].head(20)

fig = plt.figure(figsize=(20, 20))
plt.bar(name[0:10], volume_24h[0:10])

# Show Plot
plt.show()
```

- spark-submit visualize1.py hdfs://masternode:9000/user/hadoop/data/data.csv

2.2 Biểu đồ sự thay đổi % theo ngày trong 15 ngày



- Mã nguồn visualize2.py

```
import sys
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

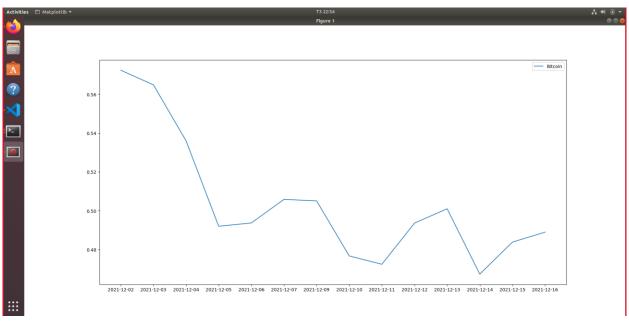
from pyspark.sql.session import SparkSession
from pyspark.sql import SQLContext
from pyspark import SparkConf, SparkContext

conf = SparkConf().setAppName("HDSD_Visual")
sc = SparkContext(conf=conf)
sc.setLogLevel("WARN")
spark = SparkSession(sc)
```

```
sqlContext = SQLContext(sc)
column = ['name', 'quote.USD.percent_change_24h', 'last_updated']
data = spark.read.csv(sys.argv[1], sep=',',inferSchema=True, header=True)
df = data.toPandas()
df.head()
dataLine = df[column]
dataLine = dataLine.to_numpy()
dataLine.shape
percent_change_24h_Bitcoin = []
date_Bitcoin = []
percent_change_24h_Ethereum = []
date_Ethereum = []
for line in dataLine:
    if (line[0] == "Bitcoin"):
        percent_change_24h_Bitcoin.append(line[1])
        day = line[2]
        day = str(day)
        date_Bitcoin.append(day[0:10])
    elif (line[0] == "Ethereum"):
        percent_change_24h_Ethereum.append(line[1])
        day = line[2]
        day = str(day)
        date_Ethereum.append(day[0:10])
# Figure Size
fig = plt.figure(figsize=(30, 20))
plt.plot(date_Bitcoin[0:15], percent_change_24h_Bitcoin[0:15], label='Bitcoin')
plt.plot(date_Ethereum[0:15],
         percent_change_24h_Ethereum[0:15], label='Ethereum')
plt.legend()
# Show Plot
plt.show()
```

- spark-submit visualize2.py hdfs://masternode:9000/user/hadoop/data/data.csv

2.3 Biểu đồ sự thay đổi giá trị theo ngày trong 15 ngày



- Mã nguồn visualize3.py

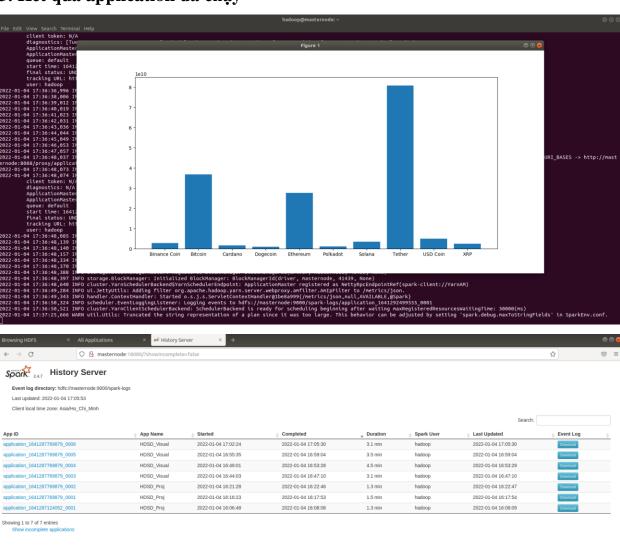
```
import sys
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from pyspark.sql.session import SparkSession
from pyspark.sql import SQLContext
from pyspark import SparkConf, SparkContext
conf = SparkConf().setAppName("HDSD_Visual")
sc = SparkContext(conf=conf)
sc.setLogLevel("WARN")
spark = SparkSession(sc)
sqlContext = SQLContext(sc)
column = ['name', 'quote.USD.price', 'last_updated']
data = spark.read.csv(sys.argv[1], sep=',',inferSchema=True, header=True)
df = data.toPandas()
df.head()
dataLine = df[column]
dataLine = dataLine.to_numpy()
dataLine.shape
price_Bitcoin = []
date_Bitcoin = []
price_Ethereum = []
date_Ethereum = []
for line in dataLine:
    if (line[0] == "Bitcoin"):
       price_Bitcoin.append(line[1]/100000)
```

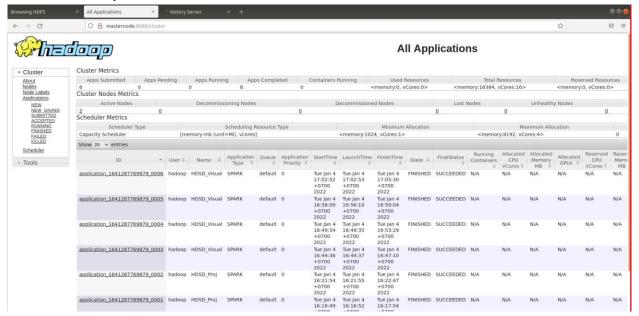
```
day = line[2]
   day = str(day)
   date_Bitcoin.append(day[0:10])
elif (line[0] == "Ethereum"):
    price_Ethereum.append(line[1])
   day = line[2]
   day = str(day)
   date_Ethereum.append(day[0:10])

# Figure Size
fig = plt.figure(figsize=(30, 20))
plt.plot(date_Bitcoin[0:15], price_Bitcoin[0:15], label='Bitcoin')
plt.legend()
# Show Plot
plt.show()
```

- spark-submit visualize3.py hdfs://masternode:9000/user/hadoop/data/data.csv

3. Kết quả application đã chạy



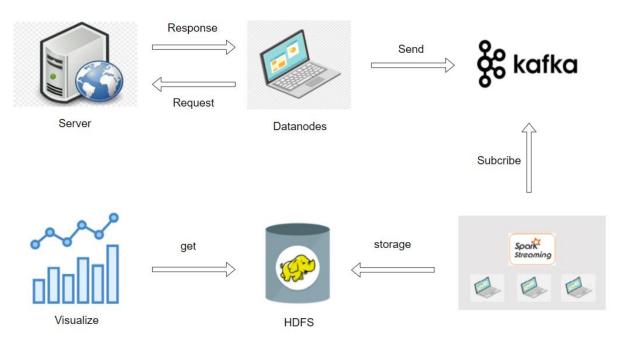


V. KÉT LUẬN

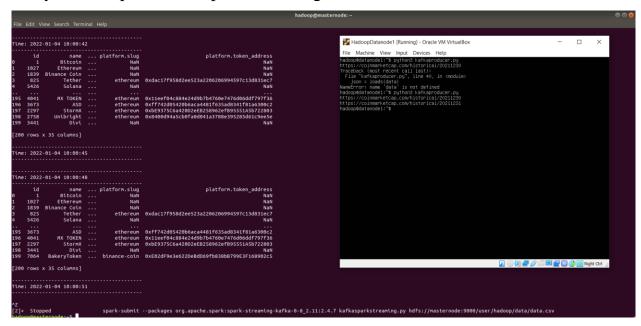
- Nhóm đã vận dụng và tự tìm hiểu một số kiến thức trong lưu trữ và xử lý dữ liệu lớn.
- Cấu hình được Hadoop Yarn, Spark, Kafka.
- Lưu trữ dữ liệu trên HDFS và visualize sử dụng spark-submit trên Yarn.
- Qua phân tích lịch sử tiền ảo, nhóm nhận thấy tiền ảo biến động mạnh, xu hướng vô cùng khó đoán trước.
- Source: https://github.com/tronghaiit2/CryptoCurrencyHistory

VI. PHŲ LŲC

- Sử dụng Kafka kết hợp cới SparkStreaming



- Đẩy dữ liệu qua kafka - spark streaming



- Source sparkstreaming.py
- File **sparkstreaming.py** nằm ở masternode để nhận dữ liệu json từ các datanode qua kafka và lưu lại vào file csv tại HDFS.

```
import sys
import os
import pandas as pd
from json import loads
packages = "org.apache.spark:spark-streaming-kafka-0-8_2.11:2.4.7"
```

```
os.environ["PYSPARK_SUBMIT_ARGS"] = ("--packages {0} pyspark-
shell".format(packages))
from pyspark.sql.types import *
from pyspark import SparkContext, SparkConf
from pyspark.streaming import StreamingContext
from pyspark.streaming.kafka import KafkaUtils
from pyspark.sql import SQLContext
from pyspark.sql.session import SparkSession
def store_data(sqlContext, value):
  data = str(value)
  if data is not None:
    json = loads(data)
    df = pd.json_normalize(json)
    df.to_csv(sys.argv[1], mode='a', header=False)
    return df
conf = SparkConf().setAppName("HDSD_Proj")
sc = SparkContext(conf=conf)
sc.setLogLevel("WARN")
spark = SparkSession(sc)
sqlContext = SQLContext(sc)
ssc = StreamingContext(sc, 3)
KAFKA BROKER = "masternode:9092"
KAFKA_TOPIC = "hdsd"
print("HDSD")
kafkaStream = KafkaUtils.createDirectStream(ssc,[KAFKA_TOPIC],{"metadata.broker.1
ist":KAFKA_BROKER})
lines = kafkaStream.map(lambda value: store_data(sqlContext, value[1]))
lines.pprint()
ssc.start()
ssc.awaitTermination()
```